

TiendaCol en tiempo real

Pipeline de datos para decisiones de e-commerce

Proyecto final — Entregable 1: Diagnóstico, requisitos y arquitectura

Nombre del proyecto	TiendaCol en tiempo real
Dominio	E-commerce: marketplace multivendedor
Profesor	Andrés Sacre Alzate
Fecha de entrega	30 de septiembre de 2026
Repositorio	https://github.com/juansimonEAFIT/Proyecto_sistemas-Intensivos-datos

Integrantes

Nombre completo	Código EAFIT
Juan Simón Ospina Martínez	1000341990
Sebastián Durán	1000315087
Daniel Arcila Salazar	1000331599
Juan José Díaz Rodríguez	1000362038

1. Definición del problema

1.1 Contexto

TiendaCol es un marketplace colombiano (empresa ficticia) donde vendedores independientes publican productos de tecnología, hogar, moda, belleza y deportes, y los clientes compran desde la web y la app móvil. Opera en las principales ciudades del país, tiene 1,5 millones de usuarios activos al mes y recibe cerca de 2.500 órdenes en un día normal, con un ticket promedio similar al del mercado colombiano (COP 212.373 en 2025 [2]).

Compite en un mercado que crece rápido: en 2025 el comercio electrónico en Colombia vendió COP 145,4 billones en 684,6 millones de transacciones, 19,9 % más transacciones que en 2024 [2]. La demanda tampoco es uniforme. En Black Friday, Cyber Monday y el Hot Sale [6] el tráfico se multiplica en minutos: Black Friday y Cyber Monday 2025 movieron en Colombia COP 2,6 billones y 15,8 millones de transacciones electrónicas en cuatro días, y el canal en línea representó el 27 % de las ventas de Black Friday y el 37 % de las de Cyber Monday [3].

1.2 El problema de negocio

- Hoy TiendaCol toma decisiones con reportes que salen **al día siguiente** de su base de datos transaccional. Eso le cuesta ventas en tres frentes:
- 1. **Productos que se agotan sin aviso durante los picos.** Un producto en tendencia que vende 5 unidades por minuto agota 300 unidades en una hora. Con reportes del día siguiente, Operaciones se entera cuando ya no puede reabastecer, avisar al vendedor ni pausar la publicidad, que sigue llevando clientes a un producto sin stock. Dos de cada tres compradores que encuentran un producto agotado terminan comprando en otra tienda [4].
 - 2. **Carritos abandonados que nadie recupera a tiempo.** El 70,22 % de los carritos de compra en línea se abandonan [1]. A esa tasa, las 2.500 órdenes diarias de TiendaCol implican unos 5.900 carritos abandonados por día. Si cada uno vale en promedio lo mismo que una orden, son cerca de COP 1.250 millones diarios. La industria recomienda enviar el primer recordatorio dentro de la primera hora [5], pero Marketing hoy solo puede enviarlo al día siguiente. Recuperar apenas el 5 % de ese valor (supuesto ilustrativo) equivaldría a unos COP 1.900 millones al mes.
 - 3. **Un embudo de compra que no se entiende.** No se sabe en qué paso (ver producto → agregar al carrito → pagar) se pierden los clientes, ni cómo cambia por categoría, ciudad o dispositivo. Comercial decide dónde invertir en promociones sin saber dónde está la fuga.

1.3 Usuarios del sistema y decisiones que toman

Usuario	Qué necesita	Qué decide con los datos	Urgencia
Operaciones / inventario	Alertas de productos que se agotarán en la próxima hora	Reabastecer desde bodega, avisar al vendedor, pausar la publicidad del producto	Minutos
Marketing / CRM	Lista de carritos abandonados de alto valor	Enviar un recordatorio o un cupón mientras el cliente sigue interesado	Menos de 1 hora
Category managers / Comercial	Ventas, conversión y ticket promedio por categoría, vendedor, ciudad y día	Qué categorías promocionar, qué vendedores apoyar, dónde invertir	Horas / diaria
Dirección	Indicadores del negocio y ventas por minuto durante los eventos	Metas, presupuesto, ajuste de campañas en curso y evaluación posterior	Minutos (en eventos) / diaria

1.4 Preguntas que el sistema debe responder

Operacionales (tiempo real)

- **P1.** ¿Qué productos se agotarán en los próximos **60 minutos** si mantienen su velocidad de venta de los últimos **15 minutos**? La alerta debe llegar a Operaciones en máximo **2 minutos** desde la venta que la dispara.
- **P2.** ¿Qué usuarios identificados dejaron un carrito con valor de **COP 500.000 o más** (unas 2,4 veces el ticket promedio del mercado [2]) sin comprar ni modificar el carrito durante **30 minutos**? La lista debe estar disponible para Marketing en máximo **5 minutos** después de cumplirse los 30, para que el recordatorio salga dentro de la primera hora [5].
- **P3.** ¿Cuántas órdenes y cuántos pesos se venden **por minuto**, en total y por categoría, durante un evento de descuentos? Cada minuto debe verse a más tardar **2 minutos** después de terminado.

Análíticas

- **P4.** ¿Cuál es la tasa de conversión del embudo vista de producto → carrito → compra por categoría, dispositivo (web de escritorio, web móvil, app) y ciudad, **por hora y por día**? Los datos deben tener como máximo **1 hora** de antigüedad.
- **P5.** ¿Cuáles son las ventas totales, el número de órdenes y el ticket promedio por categoría, vendedor, región y fecha? Mismo requisito de frescura: **1 hora**.
- **P6 (opcional).** ¿Qué pares de productos se compran juntos (misma orden) o se ven juntos (misma sesión) con más frecuencia? Se actualiza **una vez al día**.

1.5 Por qué no basta una base de datos relacional

El volumen por sí solo no es el argumento. TiendaCol genera cerca de 75 millones de eventos de navegación al mes, alrededor de 1 TB de datos crudos al año (Anexo A), y una base relacional grande podría almacenarlos. Lo que la descarta es la **combinación** de cuatro condiciones:

- **Velocidad y picos.** El tráfico pasa de unos 29 eventos por segundo en un día normal a unos 3.000 en la apertura de ofertas de Black Friday, es decir, unas **100 veces más**. Un servidor dimensionado para el pico queda ocioso el resto del año; el sistema necesita escalar horizontalmente solo cuando hace falta.
- **Cargas que compiten entre sí.** La base transaccional es la que cobra. Las consultas de P4 y P5 recorren cientos de millones de eventos, y correrlas ahí durante un pico frenaría el pago justo cuando más se vende. Por eso los reportes de hoy corren de noche, y por eso llegan con un día de retraso.
- **Variedad.** Conviven órdenes y pagos estructurados, eventos JSON cuyos campos cambian según el tipo de evento y la versión de la app, y atributos de producto distintos por categoría (tallas en moda, especificaciones técnicas en tecnología). Un esquema rígido obligaría a migraciones constantes.
- **Tiempo real.** P1, P2 y P3 pierden su valor si la respuesta tarda horas. Exigen calcular de forma continua sobre flujos de eventos, en ventanas de minutos, y no consultar periódicamente tablas ya guardadas.

2. Requisitos funcionales y no funcionales

2.1 Requisitos funcionales

Cada requisito indica a qué pregunta de negocio (Sección 1.4) responde, en qué capa del diagrama de arquitectura (Sección 3) se cumple y cómo se verifica. Los umbrales de negocio (COP 500.000, 30 minutos, etc.) son parámetros configurables.

ID	Requisito	Trazabilidad	Cómo se verifica
RF-01	El sistema debe ingestar en tiempo real los eventos de navegación de la web y la app (page_view, search, add_to_cart, remove_from_cart, checkout_start, purchase) y conservarlos sin modificar en la capa Bronze, junto con su fecha y hora de ingestión.	P1–P4, P6 · Fuente → Ingestión → Bronze	Se envían 10.000 eventos de prueba con identificador único; los 10.000 aparecen en Bronze con contenido idéntico al enviado.
RF-02	El sistema debe capturar de la base de datos transaccional las órdenes, las líneas de orden, los pagos y los cambios de estado de envío, y llevarlos a la capa Bronze.	P3, P5 · Fuente → Ingestión → Bronze	Se crean 100 órdenes de prueba y se cambia el estado de envío de 20; Bronze contiene las 100 órdenes con sus líneas y pagos, y los 20 cambios.
RF-03	El sistema debe recibir cada cambio de stock por producto y bodega y mantener el stock disponible actual de cada producto.	P1 · Fuente → Ingestión → Procesamiento	Tras 50 cambios de stock de prueba, el stock disponible que reporta el sistema coincide con el de la fuente para todos los productos afectados.
RF-04	El sistema debe cargar cada día, antes de las 6:00 a. m. (hora de Colombia), el catálogo de productos (CSV/JSON) y los datos maestros de clientes y vendedores.	P4, P5 · Fuente → Ingestión por lotes → Bronze	A las 6:00 a. m. el número de productos, clientes y vendedores cargados coincide con el de los archivos fuente del día.
RF-05	El sistema debe validar cada registro contra su esquema esperado, apartar en una zona de cuarentena los que no lo cumplan sin detener el procesamiento, y eliminar los eventos duplicados (mismo identificador de evento).	Todas · Procesamiento Bronze → Silver	En un lote de 10.000 eventos con 100 malformados y 100 duplicados, Silver queda con 9.800 eventos únicos, la cuarentena con 100 y el procesamiento no se detiene.
RF-06	El sistema debe enriquecer cada evento y cada línea de orden con la categoría, el vendedor y el precio del producto (catálogo), y con la ciudad y el departamento del cliente (datos maestros).	P1–P5 · Procesamiento Silver	En una muestra de 1.000 registros de Silver, categoría, vendedor y ciudad coinciden con el catálogo y los maestros vigentes.
RF-07	El sistema debe calcular cada minuto la velocidad de venta de cada producto (unidades vendidas en los últimos 15 minutos) y generar una alerta para Operaciones cuando el stock disponible alcance para menos de 60 minutos a esa velocidad. La alerta incluye producto, vendedor, stock, velocidad y tiempo estimado de agotamiento, y llega en máximo 2 minutos desde la venta que la dispara.	P1 · Procesamiento en tiempo real → Consumo (alertas)	Se simulan ventas a velocidad constante de un producto con stock conocido; se calcula a mano la venta con la que la cobertura baja de 60 minutos, y la alerta llega máximo 2 minutos después de esa venta.
RF-08	El sistema debe identificar los carritos abandonados de alto valor (carritos de usuarios identificados con valor de COP 500.000 o más, sin compra ni cambios durante 30 minutos) y publicar la lista para Marketing (usuario, productos, valor, hora del último evento) en máximo 5 minutos después de cumplirse los 30.	P2 · Procesamiento en tiempo real → Consumo (Marketing)	Se simulan 3 sesiones: carrito de COP 600.000 sin compra (aparece entre el minuto 30 y el 35), carrito de COP 600.000 con compra en el minuto 20 (no aparece) y carrito de COP 300.000 sin compra (no aparece).
RF-09	El sistema debe calcular para cada minuto el número de órdenes y el valor vendido en COP, en total y por categoría, y mostrarlo en un tablero de monitoreo máximo 2 minutos después de terminado ese minuto.	P3 · Procesamiento en tiempo real → Consumo (tablero de eventos)	Se envía un número conocido de compras de prueba en un mismo minuto; el tablero muestra exactamente ese número y ese valor dentro de los 2 minutos siguientes.
RF-10	El sistema debe calcular la tasa de conversión del embudo vista de producto → carrito → compra (proporción de sesiones que pasan de cada etapa a la siguiente) por categoría, dispositivo y ciudad, por hora y por día, y publicarla en la capa Gold máximo 1 hora después de terminada cada hora.	P4 · Procesamiento Silver → Gold	Con un conjunto de prueba con conteos conocidos de sesiones por etapa, la consulta a Gold devuelve las mismas tasas calculadas a mano.
RF-11	El sistema debe calcular las ventas totales, el número de órdenes y el ticket promedio por categoría, vendedor, región (ciudad y departamento) y fecha en un modelo dimensional de la capa Gold, consultable con SQL y desde un tablero para Comercial y Dirección, con datos de máximo 1 hora de antigüedad.	P5 · Gold → Consumo (tablero)	Para un día de prueba, el total de ventas y de órdenes en Gold coincide exactamente con el de la base transaccional, y cada cifra del tablero coincide con la consulta directa a Gold.
RF-12	El sistema debe ejecutar automáticamente, en el orden de sus dependencias, los procesos programados (carga diaria de catálogo y maestros, Bronze → Silver, Silver → Gold); si un paso falla, no ejecutar los pasos que dependen de él y notificar la falla.	Todas · Orquestación (transversal)	Se fuerza una falla en la carga del catálogo; los pasos dependientes no se ejecutan y se genera una notificación. Al corregir y reintentar, el flujo termina completo sin intervención manual.
RF-13 (opcional, P6)	El sistema debe identificar diariamente, para cada producto, los 10 productos que más se compran en la misma orden y los 10 que más se ven en la misma sesión.	P6 · Procesamiento → Gold o componente libre	Con un conjunto de prueba donde A y B aparecen juntos en 50 órdenes y ningún otro producto aparece con A en más de 10, B figura de primero en la lista de A.


2.2 Requisitos no funcionales

ID	Categoría	Requisito	Valor concreto	Cómo se mide
RNF-01	Escalabilidad	El sistema debe absorber el pico de navegación sin degradar la latencia de RNF-04, y crecer agregando particiones y ejecutores de Spark, no rediseñándose.	Capacidad de diseño: 5.000 eventos/s (pico de ≈ 3.000 del Anexo A más margen). Clickstream en 6 particiones (ADR-1). Una sola EC2 puede no alcanzarla (ADR-6): se reporta el máximo medido.	El generador sube la carga por escalones hasta 5.000 ev/s o hasta donde aguante la EC2. Se mide el retraso del consumidor (<i>consumer lag</i>) y la latencia de RNF-04: el retraso no debe crecer de forma sostenida.
RNF-02	Disponibilidad (CAP)	La posición CAP se define por componente. Kafka y Delta Lake priorizan consistencia (CP) ; la lista de carritos en DynamoDB prioriza disponibilidad (AP) (ADR-4).	Kafka: <i>acks=all</i> y un solo broker en el E1; en producción, 3 brokers con <i>min.insync.replicas=2</i> (CP). Delta Lake en S3: escrituras ACID con aislamiento serializable (ADR-3). DynamoDB: lectura del índice eventualmente consistente (ADR-4).	Se inspecciona la configuración de cada componente. Se detiene un broker de prueba y se verifica que el productor no confirme escrituras sin réplica suficiente.
RNF-03	Consistencia (garantía de entrega)	El sistema no debe perder eventos entre la fuente y Bronze, y no debe contar dos veces un evento duplicado.	At-least-once de la fuente a Kafka y de Kafka a Bronze y a los jobs de streaming. La deduplicación por <i>event_id</i> la hacen los jobs de streaming (RF-07 a RF-09) y Silver (RF-05). Las escrituras a Delta usan MERGE, de modo que reprocesar da el mismo resultado (ADR-1, ADR-2, ADR-3).	0 eventos perdidos y 0 duplicados en Silver y Gold: se envían 10.000 eventos de prueba y 100 de ellos se reenvían, como hace la app. Bronze conserva los 10.100 recibidos y Silver queda con 10.000 únicos.
RNF-04	Latencia	La latencia se mide del momento del evento a su disponibilidad, separando el tiempo real de la frescura analítica.	Alerta de agotamiento (RF-07) y ventas por minuto (RF-09): máx. 2 min . Lista de carritos (RF-08): máx. 5 min tras cumplirse los 30 de inactividad. Evento a Gold (RF-10, RF-11): máx. 1 hora .	Diferencia entre la hora del evento y la hora de la alerta, del tablero o de la fila en Gold, con los eventos de prueba de cada RF. Se reporta el máximo observado en la demo.
RNF-05	Tolerancia a fallos	Si un job de Spark falla, debe reanudarse solo desde donde quedó, sin perder ni duplicar eventos. Si la EC2 falla, no deben perderse los datos de Bronze, Silver y Gold.	Job de Spark: reinicio por Airflow en máx. 5 min (ADR-5) desde su <i>checkpoint</i> en S3. EC2 caída: Bronze, Silver y Gold siguen en S3 y el equipo debe recuperar el cómputo en otra EC2 con el mismo <i>docker-compose.yml</i> en un RTO máximo de 20 min . Durante la recuperación RF-07 puede incumplir temporalmente sus 2 min.	Se detiene el contenedor durante una carga y se comprueba la reanudación sin pérdidas ni duplicados. Para la EC2, se cronometra desde la detección de la caída hasta que la instancia de reemplazo consume nuevamente Kafka; debe tardar ≤ 20 min.

ID	Categoría	Requisito	Valor concreto	Cómo se mide
RNF-06	Trazabilidad	Debe poder seguirse cualquier cifra de Gold hasta el evento u orden de origen.	Bronze guarda el event_id, la fuente, la hora de ingestión y la partición y el offset de Kafka. Silver y Gold conservan event_id u order_id. Los registros rechazados quedan en quarantine/ con su causa. El time travel de Delta (ADR-3) permite reproducir una cifra pasada.	100 % de las filas de fact_funnel_event y fact_sales enlazan con su registro en Bronze mediante event_id u order_id. Se verifica con una consulta de cruce.

3. Diagrama de arquitectura de datos por capas

Fuente editable: [archivo Draw.io del repositorio \(arquitectura.drawio\)](#) · Enlace compartido: [abrir el diagrama editable en Google Drive / Draw.io](#)



Capa	Componentes (herramienta concreta)	Qué hace	RF que cumple
Fuente	Generador Python con Faker es_C0; archivos REES46 y Olist	Emite clickstream, órdenes y cambios de stock como JSON continuo; publica catálogo y maestros en CSV cada día antes de las 6:00 a. m. La ciudad de una sesión, aun anónima, se genera como atributo de contexto de la sesión, sin identificar a la persona.	RF-01, RF-02, RF-03, RF-04
Ingestión	Apache Kafka en EC2; carga diaria de Airflow hacia S3	Kafka recibe los flujos continuos con entrega <i>at-least-once</i> , particiones y retención para <i>replay</i> . Airflow deposita la carga diaria directamente en Bronze.	RF-01, RF-02, RF-03, RF-04
Procesamiento	Apache Spark Structured Streaming y Spark SQL en EC2	Streaming mantiene el stock como estado y calcula RF-07, RF-08 y RF-09 sin escribir Silver. El batch horario es el único dueño de Silver: valida, manda inválidos a cuarentena, deduplica, enriquece y actualiza Gold con MERGE idempotente.	RF-03, RF-05, RF-06, RF-07, RF-08, RF-09, RF-10, RF-11, RF-13
Almacenamiento: Bronze	Delta Lake en Amazon S3 (bronze/)	Conserva el dato recibido y sus metadatos de ingesta, sin aplicar reglas de negocio; permite releerlo y auditar la fuente.	RF-01, RF-02, RF-04
Almacenamiento: Silver	Delta Lake en Amazon S3 (silver/ y quarantine/)	Guarda eventos válidos, deduplicados y enriquecidos; separa registros inválidos con la causa del rechazo.	RF-05, RF-06
Almacenamiento: Gold	Delta Lake en Amazon S3 (gold/), modelo estrella	Publica fact_sales, fact_funnel_event y dimensiones conformadas para el batch, más agg_sales_minute para la ruta de baja latencia. Se particiona por fecha del evento.	RF-09, RF-10, RF-11, RF-13
Consumo	Amazon Athena, Apache Superset, Amazon SNS y Amazon DynamoDB	Athena consulta Gold con SQL; Superset muestra el embudo, ventas y ventas por minuto; SNS entrega alertas de agotamiento; DynamoDB sirve la lista de carritos a Marketing.	RF-07, RF-08, RF-09, RF-11
Orquestación (transversal)	Apache Airflow con LocalExecutor en EC2	Programa las cargas diaria y horaria, supervisa los jobs continuos, aplica dependencias, reintentos y notificación de fallos.	RF-12

4. Justificación de decisiones técnicas (ADRs)

ADR-1. Motor de streaming y garantía de entrega

Contexto. Los RF-01, RF-07, RF-08 y RF-09 exigen tiempo real, y el enunciado prohíbe simularlo con batch. El tráfico pasa de ≈ 29 eventos/s a ≈ 3.000 en la apertura de ofertas, con una capacidad objetivo de 5.000 eventos/s (Anexo A). Hace falta un transporte que amortigüe los picos, conserve los eventos para reprocesarlos y reparta el trabajo en paralelo. La app reenvía eventos al perder conexión, así que los duplicados nacen en la fuente (RF-05). Por el ADR-6, el transporte corre en un contenedor de la EC2 compartida y se descartan los servicios que cobran por hora encendidos.

Alternativas consideradas.

Alternativa	Ventajas para este problema	Desventajas / por qué se descarta
Kafka	Referencia de la guía del curso (S6-S7). Corre en el <code>docker-compose.yml</code> sin cobrar por hora. Particiones con orden por clave, retención para <i>replay</i> e integración con Spark, que guarda los <i>offsets</i> en su <i>checkpoint</i> .	Hay que operarlo y consume memoria de la EC2. Un solo broker no tiene réplicas.
Kinesis	Gestionado: AWS lo opera y lo escala por <i>shards</i> .	Cobra por <i>shard</i> -hora encendido: con USD 50 de presupuesto, un recurso olvidado pone en riesgo la cuenta (ADR-6). No corre en un <code>docker-compose.yml</code> , que exige el E2.
Redpanda	Compatible con la API de Kafka y más liviano.	La guía no lo cita y el equipo no lo ha usado: su ahorro no compensa aprender otra herramienta antes de S16.

Decisión. Se elige **Apache Kafka** en un contenedor de la EC2, con garantía ***at-least-once***. ***At-most-once*** puede perder un `add_to_cart` y esconder un carrito del RF-08, algo que no se recupera; un duplicado, en cambio, se elimina por `event_id`. ***Exactly-once*** de extremo a extremo exigiría un destino transaccional en cada salida [12][13]; aquí se logra el mismo efecto solo donde importa, en Delta Lake con MERGE (ADR-3). Se configura así: el productor usa `acks=all` e idempotencia, que evita duplicados por sus propios reintentos [12]; Spark avanza los *offsets* de su *checkpoint* después de escribir, así que tras una falla lee el último lote [13]; y los duplicados de la fuente y de esa relectura se eliminan por `event_id` en los jobs de streaming (ADR-2) y en Silver (RF-05).

Diseño de topics aprobado para el E1:

Topic	Clave de partición	Particiones	Por qué
clickstream	<code>user_id</code> (<code>session_id</code> si es anónimo)	6	El orden solo existe dentro de una partición [12]: así los eventos de un usuario llegan en orden, lo que necesita el RF-08 para saber si hubo compra tras el carrito. A 5.000 ev/s son ≈ 830 ev/s por partición, con hasta seis tareas de Spark en paralelo.
orders	<code>order_id</code>	3	Volumen bajo (24.000 órdenes en Black Friday). Con <code>product_id</code> como clave, un producto en tendencia saturaría una partición.
stock_changes	<code>product_id</code>	3	Los cambios de stock de un producto deben procesarse en orden (RF-03).

La retención es de **7 días**, para reprocesar tras un fin de semana con el laboratorio apagado por su temporizador (ADR-6). El RF-07 agrupa por producto, pero Spark reagrupa al calcular la ventana, y así se evita la partición caliente.

Consecuencias.

- **Los duplicados llegan a los consumidores:** todo job deduplica por `event_id`, a costa de memoria y algo de latencia.
- **Un solo broker no tiene réplicas.** Si cae o pierde su disco, el flujo se detiene y pueden perderse eventos no leídos. En producción serían 3 brokers, factor de replicación 3 y `min.insync.replicas=2`.
- **El orden existe solo por usuario:** un cálculo por producto obliga a Spark a reagrupar los datos.
- **Las particiones no se reducen, y aumentarlas cambia a qué partición va cada clave:** por eso se fijan desde ahora con margen.
- **Costo de recursos.** La retención ocupa ≈ 18 GB en un día normal y ≈ 170 GB en Black Friday. La demo usa 100 GB gp3 y un volumen acotado; sostener el pico completo requeriría ampliar y distribuir Kafka. Además, Kafka comparte memoria con Spark y Airflow, y su versión debe ser compatible con el conector de Spark.

ADR-2. Motor de procesamiento

Contexto. Los RF-07 (ventana de 15 min cada minuto), RF-08 (carrito inactivo durante 30 min) y RF-09 (ventas por minuto) necesitan ventanas de tiempo, con resultados en máximo 2 minutos (5 minutos tras los 30 en el RF-08). El RF-06 pide un *join* con el catálogo, y los RF-10 y RF-11, agregaciones horarias. El enunciado exige Spark en una transformación no trivial y prohíbe resolver el tiempo real con batch. Por el ADR-1 los jobs reciben duplicados, y por el ADR-6 comparten la memoria de la EC2.

Alternativas consideradas.

Alternativa	Ventajas para este problema	Desventajas / por qué se descarta
Spark Structured Streaming	<i>Micro-batch</i> con latencia de segundos, que cumple los 2 min con margen. Ventanas deslizantes (RF-07), fijas (RF-09) y de sesión (RF-08), <i>watermarks</i> y <i>checkpoints</i> [13][14]. El mismo motor sirve para el batch de Silver y Gold.	La latencia mínima es la del lote, no la del evento. Los lotes pequeños crean archivos pequeños en Delta Lake.
Flink	Procesa evento por evento, con milisegundos, y maneja bien el estado.	Esa latencia no aporta: el problema tolera minutos. Spark tendría que aparecer igual en Silver y Gold, y habría dos motores en una EC2 compartida.
Batch puro	Simple, y suficiente para los RF-05, RF-06, RF-10 y RF-11.	No entrega una alerta en 2 min sin volverse <i>micro-batch</i> , y el enunciado lo prohíbe en tiempo real. Se conserva en el batch horario.

Decisión. Se elige **Spark Structured Streaming** para el tiempo real y **Spark SQL en batch horario** para Silver y Gold, con un *trigger* de 30 segundos que cumple los 2 minutos con margen.

- **Streaming (lee de Kafka).** Escribe el dato crudo a Bronze y calcula los RF-07, RF-08 y RF-09. No escribe en Silver: lo hace el batch horario (ADR-5), que valida, aparta en cuarentena y deduplica (RF-05). Los registros que no cumplen el esquema se ignoran en el streaming y quedan en Bronze.
- **RF-07, ventana deslizante.** 15 min cada minuto por producto, combinada con el stock actual que el job guarda como estado por clave desde `stock_changes` (RF-03). Sale en modo `update` y publica la alerta por SNS si la cobertura baja de 60 min.
- **RF-08, ventana de sesión.** Hueco de 30 min por usuario. La ausencia de compra se detecta al cerrarse la sesión: si no tiene ningún `purchase`, el usuario está identificado y el carrito vale COP 500.000 o más, se escribe en DynamoDB con `user_id` como clave (ADR-4).
- **RF-09, ventana fija.** 1 min, con órdenes y COP en total y por categoría (*join* con el catálogo), escrita en una tabla Gold de métricas por minuto que Superset consulta por Athena. El batch horario corrige lo que llegó tarde.
- **Deduplicación y *watermarks*.** Se deduplica por `event_id` con un *watermark*, que acota la memoria usada [14]: **1 min** para los RF-07 y RF-09 y **3 min** para el RF-08. El resultado de una ventana sale al pasar el *watermark* [14]: el RF-09 sale en ≈ 1,5 min (cumple los 2) y una sesión del RF-08 en ≈ 33,5 min tras su último evento (cumple los 35).
- **Checkpoints en S3,** no en el disco de la EC2, para reanudar aunque se pierda la instancia (ADR-6). Los duplicados de una relectura los absorbe MERGE en Delta (ADR-3) [13].
- **Una sola aplicación de Spark con varias consultas,** para pagar una sola vez la memoria del proceso principal.

Consecuencias.

- **La latencia mínima es la del lote (30 s).** Para respuestas en milisegundos habría que usar Flink.
- **El *watermark* descarta lo tardío.** Un evento con más de 1 min de retraso no cuenta en tiempo real, y un duplicado posterior al *watermark* no se elimina en el streaming. El batch horario lo corrige, así que las cifras de tiempo real y de Gold pueden diferir hasta esa hora.

- **El RF-08 queda justo en el límite de 5 min** (3 min de *watermark* más 30 s de *trigger*): hay que medirlo en el E2 y, si no alcanza, bajar el *watermark*. Además, el *watermark* solo avanza con eventos nuevos, así que con poco tráfico una ventana tarda más en cerrarse.
- **Si se cae la aplicación de Spark, se caen todos los jobs**. Airflow la reinicia en máximo 5 min (ADR-5) y, en ese lapso, el RF-07 no cumple sus 2 min.
- **Costos de operación**. Los lotes de 30 s crean archivos pequeños que el DAG horario debe compactar (ADR-3), y consultar las métricas por Athena y Superset gasta parte de los 2 min del RF-09.
- **Silver se actualiza cada hora**, suficiente para los RF-10 y RF-11.

ADR-3. Formato de la capa Gold y modelo dimensional

Contexto. Los RF-10 y RF-11 exigen que Gold responda con una frescura máxima de una hora la conversión del embudo y las ventas por categoría, vendedor, región y fecha. Spark escribe simultáneamente resultados de streaming y de procesos horarios sobre S3 (ADR-2 y ADR-6), por lo que un conjunto de archivos Parquet sin capa transaccional podría dejar lecturas parciales durante una falla o un reintento. Además, el catálogo cambia cada día, llegan atributos distintos según la categoría y la garantía *at-least-once* obliga a realizar escrituras idempotentes. Gold necesita, por tanto, transacciones ACID, control y evolución del esquema, MERGE para corregir o reprocesar datos y versiones auditables. También debe ser consultable desde Spark y Athena, y presentar un modelo que los usuarios puedan recorrer sin reconstruir las relaciones operacionales.

Alternativas consideradas.

Alternativa	Ventajas para este problema	Desventajas / por qué se descarta
Delta Lake	Ofrece transacciones ACID con aislamiento serializable, unifica lectura y escritura <i>batch</i> y <i>streaming</i> , permite MERGE, evolución controlada del esquema y <i>time travel</i> sobre S3 [9]. Tiene integración directa con Spark y Athena puede consultar sus tablas con SQL y aprovechar estadísticas para omitir archivos [10]. El equipo ya usó esta combinación en el laboratorio del curso.	La partición es explícita y debe diseñarse y mantenerse; el log <i>_delta_log</i> y los archivos pequeños requieren compactación y limpieza periódicas. Su mejor integración sigue siendo con Spark, lo que aumenta el acoplamiento al ADR-2.
Apache Iceberg	También ofrece aislamiento serializable, evolución segura del esquema, <i>time travel</i> y compatibilidad con Spark. Su particionamiento oculto y la evolución de la especificación permiten cambiar la distribución física sin reescribir consultas [11].	Para este volumen y un único motor de escritura, la evolución avanzada de particiones no compensa incorporar otro catálogo y una tecnología que el equipo no ha usado. La implementación y la defensa tendrían más riesgo sin mejorar las preguntas P4 y P5.

Decisión. Se elige **Delta Lake sobre Amazon S3** para Bronze, Silver y Gold. En Gold se implementa un esquema en estrella con dimensiones conformadas y claves sustitutas:

Tabla	Grano	Contenido principal
fact_sales	Una línea de producto de una orden confirmada	order_id como dimensión degenerada, cantidad, precio unitario pagado, descuento y valor neto. El precio pagado queda en el hecho para no cambiar la historia cuando se actualiza el catálogo.
fact_funnel_event	Un evento válido de page_view, add_to_cart o purchase para un producto dentro de una sesión	event_id, session_id, etapa, cantidad y claves de tiempo, producto, cliente, ubicación y dispositivo. Conserva al cliente desconocido para sesiones anónimas.
agg_sales_minute	Un minuto y categoría; incluye una fila total por minuto	Cantidad de órdenes y ventas en COP. Spark Structured Streaming hace MERGE por (minute_start, category_id); Athena la consulta y Superset la visualiza con latencia objetivo menor de 2 minutos.
dim_datetime	Un minuto calendario	Fecha, hora, día, semana y mes en hora de Colombia.
dim_product	Una versión de un producto	Producto, nombre y categoría. Usa SCD tipo 2 (valid_from, valid_to, is_current) para conservar cambios de categoría; los nuevos atributos opcionales evolucionan el esquema.
dim_customer	Un cliente identificado, más la fila "desconocido"	Identificador seudonimizado y estado de identificación.
dim_seller	Un vendedor	Identificador y atributos comerciales del vendedor.
dim_location	Una ciudad y departamento	Ciudad del contexto de sesión o de la orden; una fila "desconocida" evita perder eventos sin ubicación.
dim_device	Un tipo de dispositivo o canal	Web de escritorio, web móvil o app.

P4 se obtiene contando sesiones distintas que alcanzan cada etapa de fact_funnel_event y dividiendo las que compran por las que ven un producto, agrupadas por categoría de dim_product, dispositivo, ciudad y hora o día. P5 suma el valor neto de fact_sales, cuenta order_id distintos y calcula el ticket promedio como **ventas / órdenes** —nunca como suma de promedios— por categoría, vendedor, región y fecha. Las tablas Gold se particionan físicamente por la fecha del evento; no se particionan por categoría o vendedor para evitar muchas particiones pequeñas. Spark hace escrituras idempotentes con MERGE por event_id, por (order_id, product_id) o por (minute_start, category_id), según la tabla, y Athena consulta las tablas Gold con SQL.

Consecuencias.

- Las transacciones ACID evitan que Athena lea una actualización incompleta, y el *time travel* permite reproducir una cifra y auditar cambios. A cambio, el equipo debe administrar el historial y definir políticas de retención y VACUUM sin borrar versiones todavía necesarias.
- La historia del producto queda correcta mediante SCD tipo 2 y el precio pagado permanece en el hecho. Esto aumenta filas y obliga a resolver la clave sustituta vigente durante el enriquecimiento de Silver a Gold.
- La partición diaria favorece P4 y P5, que filtran por tiempo, pero una consulta puntual por vendedor sin rango temporal escaneará más archivos. Los micro-batches pueden producir archivos pequeños, por lo que el DAG horario debe compactarlos.
- Delta reduce el riesgo de implementación por su integración con Spark y la experiencia previa del equipo, pero crea mayor dependencia de ese ecosistema que Iceberg.
- El esquema estrella duplica algunos atributos descriptivos y requiere procesos de dimensiones, pero simplifica las consultas y evita que Comercial tenga que unir el modelo transaccional. Los pares de productos del RF-13, si se implementan, se materializan como una tabla Gold derivada y no cambian el grano de los dos hechos obligatorios.

ADR-4. Componente libre

Contexto. El RF-08 exige publicar para Marketing, en máximo 5 minutos, la lista de carritos abandonados de alto valor. Eso tiene dos patrones de acceso: buscar el carrito de un usuario puntual y listar los carritos abandonados del día, de mayor a menor valor. El job de streaming actualiza estos registros sin parar, y con la garantía at-least-once del ADR-1 puede escribir el mismo evento más de una vez. El lakehouse no sirve para esto: Delta Lake o Iceberg en S3 son buenos para recorrer muchos datos de una vez, no para responder en milisegundos por una clave que cambia cada pocos segundos. Por el ADR-6, el componente tiene que correr en un contenedor o cobrar por uso, y la EC2 ya comparte su memoria entre el broker, Spark y Airflow.

Alternativas consideradas.

sus checkpoints (ADR-2). En dag_horario, esperar_bronze es un sensor que no deja avanzar hasta que el streaming haya escrito en Bronze la hora completa, y enriquecer también espera a que el catálogo del día esté cargado. Cada paso se reintenta ante fallas pasajeras y, si falla del todo, los que dependen de él no corren y un aviso de falla notifica al equipo, como pide el RF-12. Todos los pasos son idempotentes: en lugar de agregar filas, cada uno sobrescribe la partición de su intervalo o hace un MERGE, según el formato del ADR-3. Así, un reintento o un backfill deja el mismo resultado que una sola ejecución. La zona horaria se configura explícitamente, porque Airflow programa en UTC por defecto y el RF-04 está en hora de Colombia.

Consecuencias.

- **Airflow consume memoria que el resto del pipeline no puede usar.** Aun con el LocalExecutor, obliga a partir de una EC2 t3.xlarge de 16 GiB y a medir el consumo conjunto en S13 (ADR-6).
- **Mientras la EC2 está apagada, no corre ningún DAG.** Con el temporizador del Learner Lab, la carga de las 5:00 a. m. no se ejecuta si el laboratorio está cerrado. Al encenderlo, los intervalos pendientes se recuperan con backfill, algo que solo es seguro porque los pasos son idempotentes.
- **La supervisión del streaming tiene un retraso.** Si un job se cae justo después de una revisión, pasan hasta 5 minutos antes de reiniciarlo. En ese tiempo el RF-07 no cumple su máximo de 2 minutos.
- **El LocalExecutor no reparte trabajo entre máquinas.** Si el pipeline creciera hacia los 5.000 eventos por segundo del Anexo A, habría que volver al CeleryExecutor o a un despliegue con varios workers.
- **Se renuncia al linaje de tablas de Dagster.** El linaje de Bronze a Gold tendrá que documentarse aparte para el requisito de trazabilidad.

ADR-6. Plataforma (opcional)

Contexto. El pipeline de TiendaCol necesita correr al mismo tiempo cinco piezas: un broker de streaming, un motor de procesamiento con Spark, el almacenamiento Bronze/Silver/Gold en formato de tabla abierta, un orquestador y el componente libre. La plataforma debe cumplir tres condiciones del proyecto: el E2 exige un docker-compose.yml que levante el pipeline desde cero siguiendo el README, la demo de S16 corre en vivo frente al docente, y cualquier integrante debe poder reproducir el entorno. El equipo cuenta con AWS Academy Learner Lab y adopta un tope de diseño de USD 50. El laboratorio usa sesiones temporales, restringe IAM y trabaja en us-east-1; por eso deben preferirse recursos reemplazables y credenciales que nunca entren al repositorio. Por último, el sistema está dimensionado para 5.000 eventos por segundo (Anexo A), pero la demo procesa un volumen menor: el diseño debe mostrar cómo crecer sin pagar hoy por capacidad ociosa.

El equipo adopta **USD 50 como tope de diseño**, independientemente del crédito visible en la cuenta: reserva USD 5 como margen y detiene nuevos consumos al llegar a USD 45. P4 revisa el gasto al finalizar cada sesión y elimina los recursos de prueba que no formen parte de la demo.

Alternativas consideradas.

Alternativa	Ventajas para este problema	Desventajas / por qué se descarta
AWS todo administrado (Kinesis o MSK, EMR, MWAA)	El equipo no instala ni opera servidores: AWS administra el broker, el procesamiento y el orquestador, y los escala solo.	MSK, EMR y MWAA cobran por cada hora encendidos, aunque no procesen nada. Según el material del curso (Clase 6), un clúster EMR encendido 48 horas cuesta cerca de USD 14: con USD 50 y una cuenta que se borra al agotarlos, un servicio olvidado pone en riesgo todo el proyecto. Además, estos servicios no se pueden levantar con un docker-compose.yml, que es lo que exige el E2.
AWS híbrido: contenedores en EC2 + lakehouse en S3	El cómputo (broker, Spark y orquestador) corre en contenedores sobre una EC2, que deja de cobrar cuando se apaga. El almacenamiento (Bronze, Silver y Gold en S3, en el formato de tabla abierta que elija el ADR-3) cobra por uso y sobrevive si la EC2 falla. El mismo docker-compose.yml corre en un portátil y en la nube. Reutiliza lo hecho en el Lab 1b: tablas Delta Lake en S3 consultadas con Athena.	La EC2 es un punto único de falla del cómputo: si se cae, el streaming se detiene hasta que se levante otra. El equipo administra las versiones y la configuración de cada contenedor. Los contenedores necesitan permiso para escribir en S3 sin claves que caduquen a mitad de la demo.
Local con Docker	No cuesta nada, no tiene temporizador de sesión y la demo no depende de la red del salón.	Las cinco piezas tienen que caber a la vez en el portátil de la demo, y cada integrante tiene una máquina distinta. Los datos quedan en un disco local y no en almacenamiento de objetos, que es la base del lakehouse que enseña el curso. No hay forma de crecer hacia los 5.000 eventos por segundo del Anexo A.
GCP	Tiene servicios equivalentes para cada capa (Pub/Sub, Dataproc, Cloud Composer, BigQuery) y un programa de créditos educativos.	El equipo ya tiene AWS Academy activo y todos los laboratorios del curso se hicieron en AWS, así que cambiar de nube suma aprendizaje sin resolver ningún requisito. Dataproc y Cloud Composer también cobran por hora encendidos, así que el problema de presupuesto de la primera alternativa se repite.

Decisión. Se elige el enfoque híbrido en AWS Academy, con una regla de costo: un servicio se usa administrado solo si cobra por uso; si cobraría por hora encendido, corre en un contenedor. Por eso el broker, Spark y el orquestador corren con docker-compose sobre una instancia EC2, y Bronze, Silver y Gold viven en S3 en formato de tabla abierta. La decisión se apoya en la separación de cómputo y almacenamiento: el cómputo es reemplazable (si la EC2 falla, se levanta otra con el mismo docker-compose.yml) y los datos persisten en S3. El mismo archivo levanta el pipeline en el portátil de cualquier integrante y en la nube. Los contenedores usan el perfil de instancia precreado por el laboratorio; si este no puede asociarse, reciben credenciales temporales mediante un .env excluido de Git.

Para la demo se parte de una **EC2 t3.xlarge (4 vCPU, 16 GiB RAM) con 100 GB gp3** en us-east-1. Se usa el perfil de instancia precreado por el laboratorio cuando esté disponible; si el Learner Lab no permite asociarlo, los contenedores reciben las credenciales temporales de la sesión mediante un archivo .env excluido de Git. En S13 se mide memoria y disco: si la instancia permitida no alcanza, se reducen los ejecutores y el volumen de la demo, sin cambiar la arquitectura lógica.

Consecuencias.

- **La EC2 es un punto único de falla del cómputo.** Si se cae, el streaming y el orquestador se detienen hasta levantar otra instancia. Los datos no se pierden, porque están en S3.
- **El equipo opera los contenedores.** Nadie administra por ellos las versiones del broker, de Spark y del formato de tabla, y esas versiones tienen que ser compatibles entre sí. Este riesgo pasa a la Sección 5.
- **El pipeline no corre de forma continua.** El temporizador del Learner Lab apaga la EC2 al terminar cada sesión. Para la demo hay que iniciar el laboratorio con anticipación, y el procesamiento tiene que poder reanudarse desde donde quedó (checkpoints, ADR-2).
- **Una sola EC2 no alcanza los 5.000 eventos por segundo del Anexo A.** Llegar a ese volumen exigiría repartir el cómputo en varias máquinas o pasarlo a servicios administrados. El almacenamiento en S3 no tendría que cambiar.
- **El disco de la EC2 sigue cobrando con la instancia apagada,** aunque su costo es bajo frente al de un servicio encendido.
- **Condiciona los otros ADRs.** Descarta los servicios que cobran por hora encendidos: Kinesis para el ADR-1, MWAA para el ADR-5, y bases administradas como RDS o DocumentDB para el ADR-4. Deja abiertos los que corren en contenedores o cobran por uso, como Athena o DynamoDB en modo bajo demanda, si el laboratorio los permite.

5. Plan de implementación

5.1 Responsabilidades

Cada integrante implementa en el E2 los componentes de la sección del E1 que escribió. Cada RF tiene un responsable, salvo el RF-08, que se reparte: P2 detecta los carritos abandonados en el streaming y P4 los publica en DynamoDB.

Integrante	Componente(s) que implementa	RF que cubre
P1 · Juan Simón Ospina Martínez	Generador de eventos que simula las fuentes (clickstream, órdenes, stock, catálogo), carga diaria del catálogo y los maestros, y las pruebas de la columna "Cómo se verifica" de la Sección 2.1	RF-04 · pruebas de todos los RF
P2 · Sebastián Durán	Kafka, ingesta de las fuentes a Bronze y los jobs de streaming con Spark	RF-01, RF-02, RF-03, RF-07, RF-08, RF-09
P3 · Daniel Arcila Salazar	Bronze → Silver → Gold con Spark, modelo dimensional de Gold y consultas de consumo	RF-05, RF-06, RF-10, RF-11 · RF-13 si hay tiempo
P4 · Juan José Díaz Rodríguez	docker-compose.yml, EC2 y S3, los tres DAG de Airflow, la tabla de DynamoDB, README, bitácora de IA y PR	RF-12 · publicación del RF-08

5.2 Cronograma hasta S16

Semana	Hito	Responsable(s)	Criterio de "terminado"
S13	Esqueleto de punta a punta: docker-compose.yml mínimo con Kafka, Spark y Airflow sobre la EC2, versiones fijadas, tabla de DynamoDB creada. Ajuste de los ADR con la retroalimentación del E1	P4 (plataforma), P2 (Kafka), P1 (generador)	Un evento del generador llega a Bronze en S3. docker compose up levanta sin errores. La memoria usada por la EC2 queda medida y anotada
S14	Streaming y Silver: jobs de RF-07, RF-08 y RF-09; validación, cuarentena y deduplicación; enriquecimiento; dag_diario y dag_horario corriendo	P2, P3, P4	Pasan las pruebas de RF-05, RF-06, RF-07, RF-08 y RF-09 de la Sección 2.1
S15	Gold y consumo: modelo dimensional, consultas de P4 y P5, dag_streaming, README, bitácora y borrador de slides. Explicación cruzada de componentes	Todos	Un integrante que no escribió el código levanta el pipeline desde cero siguiendo el README. Pasan todas las pruebas de la Sección 2.1
S16	Presentación, demo en vivo y defensa	Todos	PR final abierto y demo ensayada de principio a fin el día anterior

5.3 Riesgos técnicos y mitigación

Riesgo	Probabilidad	Impacto	Mitigación
Se agota el presupuesto de AWS Academy y se borra la cuenta (ADR-6)	Media	Alto	Terminar el laboratorio al cerrar cada sesión y no usar servicios que cobren por hora. P4 revisa el gasto cada semana. El código vive en git, no solo en la EC2.
La EC2 no aguanta a la vez Kafka, Spark y Airflow (ADR-5, ADR-6)	Media	Alto	Medir la memoria con el compose mínimo en S13 antes de elegir el tamaño de la instancia. Airflow con LocalExecutor y límite de memoria por contenedor.
Versiones incompatibles entre Spark, el conector de Kafka y el formato de tabla (ADR-1 a ADR-3)	Media	Alto	Fijar las versiones exactas en el compose desde S13 y probar un camino mínimo de punta a punta antes de construir lo demás.
El Learner Lab no permite crear tablas en DynamoDB (ADR-4)	Baja	Medio	Probarlo como primer gate de S13 creando y borrando una tabla bajo demanda. Plan B: MongoDB en contenedor y registro explícito del cambio frente al ADR-4.
Falla la demo en vivo por la red, la sesión del laboratorio o las credenciales	Media	Alto	Ensayo completo el día anterior, iniciar el laboratorio con anticipación y tener un dataset precargado. Plan B: correr el mismo compose en un portátil (ADR-6).
Un integrante no sabe defender una parte que no implementó	Media	Alto	En S15, cada integrante le explica su componente a otro y el equipo hace un simulacro con las preguntas típicas de la guía.

Anexo A. Supuestos de dimensionamiento de TiendaCol

Valores supuestos para la empresa ficticia, coherentes con el mercado colombiano [2][3]. Los requisitos no funcionales (Sección 2.2) usan estas mismas cifras.

Supuesto	Día normal	Black Friday / Cyber Monday
Usuarios activos al mes	1,5 millones	—
Sesiones por día	100.000	800.000
Eventos por sesión	25	30
Eventos por día	2,5 millones	24 millones
Eventos por segundo, promedio del día	≈ 29	≈ 280
Eventos por segundo, hora pico	≈ 55 (8 % del tráfico del día)	≈ 1.000 (15 % del tráfico del día)
Eventos por segundo, minutos de apertura de ofertas	—	≈ 3.000 (3 veces la hora pico)
Capacidad objetivo con margen	—	5.000 eventos/s
Conversión de sesión a orden	2,5 %	3 %
Órdenes por día	2.500	24.000
Ventas por día (ticket de COP 212.373 [2])	≈ COP 530 millones	≈ COP 5.100 millones
Eventos de navegación al mes	≈ 75 millones	—
Datos crudos al año (≈ 1 KB por evento)	≈ 1 TB	—

Como control de realismo: las ventas anuales de TiendaCol (≈ COP 194.000 millones) serían cerca del 0,13 % del comercio electrónico colombiano de 2025 [2], una escala plausible para un marketplace mediano.

Referencias

1. Baymard Institute. *Cart Abandonment Rate Statistics* (promedio de 50 estudios, actualizado el 22 de septiembre de 2025). <https://baymard.com/lists/cart-abandonment-rate>
2. Cámara Colombiana de Comercio Electrónico (CCCE). *Informe de cierre ecommerce 2025, versión pública* (febrero de 2026). <https://ccce.org.co/noticias/informe-de-cierre-ecommerce-2025-version-publica/>
3. Infobae, con datos de Credibanco. *Black Friday y Cyber Monday 2025 dejaron ventas por encima de 2,6 billones de pesos en Colombia* (6 de diciembre de 2025). <https://www.infobae.com/tecnol/2025/12/06/black-friday-y-cyber-monday-2025-dejaron-ventas-por-encima-de-26-billones-de-pesos-en-colombia/>
4. SGB Media, sobre la encuesta de AlixPartners (2024). *Study: Out-of-Stocks Drive 66 Percent of Consumers to Another Retailer*. <https://sgbonline.com/study-out-of-stocks-drive-66-percent-of-consumers-to-another-retailer/>
5. Rejoiner. *When Is the Best Time to Send an Abandoned Cart Email?* (fuente de la industria). <https://www.rejoiner.com/resources/abandoned-cart-email-timing>
6. Cámara Colombiana de Comercio Electrónico (CCCE). *Llega una nueva versión de Hot Sale en Colombia* (2025). <https://ccce.org.co/noticias/llega-una-nueva-version-de-hotsale-en-colombia/>
7. Apache Software Foundation. *Running Airflow in Docker*, documentación de Apache Airflow 3.3.2 (consultada el 29 de septiembre de 2026). <https://airflow.apache.org/docs/apache-airflow/stable/howto/docker-compose/index.html>
8. Amazon Web Services. *DynamoDB read consistency*, Amazon DynamoDB Developer Guide (consultada el 29 de septiembre de 2026). <https://docs.aws.amazon.com/amazondynamodb/latest/developerguide/HowItWorks.ReadConsistency.html>
9. Delta Lake. *Welcome to the Delta Lake documentation* (consultada el 29 de septiembre de 2026). <https://docs.delta.io/>
10. Amazon Web Services. *Query Delta Lake tables with SQL*, Amazon Athena User Guide (consultada el 29 de septiembre de 2026). <https://docs.aws.amazon.com/athena/latest/ug/delta-lake-tables-querying.html>
11. Apache Software Foundation. *Evolution*, Apache Iceberg documentation (consultada el 29 de septiembre de 2026). <https://iceberg.apache.org/docs/latest/evolution/>
12. Apache Software Foundation. *Design: Message Delivery Semantics*, documentación de Apache Kafka (consultada el 30 de septiembre de 2026). <https://kafka.apache.org/43/design/design/>
13. Apache Software Foundation. *Structured Streaming Programming Guide*, documentación de Apache Spark (consultada el 30 de septiembre de 2026). <https://spark.apache.org/docs/latest/streaming/getting-started.html>
14. Apache Software Foundation. *Structured Streaming Programming Guide: APIs on DataFrames and Datasets* (ventanas, watermarks, deduplicación y joins), documentación de Apache Spark (consultada el 30 de septiembre de 2026). <https://spark.apache.org/docs/latest/streaming/apis-on-dataframes-and-datasets.html>